

Sprawozdanie PSI	
IT GR.3	Data: 09.04.2026
Tadeusz Kogut, Szymon Krzysztofik	

Kamień Milowy 1: Określenie tematu, celu projektu i stosu technologicznego

Temat projektu

Zadaniem modelu jest przyporządkowanie wejściowego zdjęcia przedstawiającego psa do jednej ze 120 zdefiniowanych klas (ras). System opiera swoje wnioskowanie na dystrybucji prawdopodobieństwa generowanej przez ostatnią warstwę sieci (funkcja aktywacji *Softmax*). Zwrócenie wektora prawdopodobieństw dla klas typu *Top-3* pozwala nie tylko na wskazanie rasy dominującej, ale również na interpretację wizualnego podobieństwa w przypadku psów o niejednoznacznych cechach fenotypowych (symulacja analizy mieszanek rasowych).

Cel projektu

Głównym celem inżynierskim jest zaprojektowanie, wytrenowanie oraz ewaluacja głębokiej sieci neuronowej zdolnej do precyzyjnej identyfikacji ras psów na podstawie surowych plików graficznych, a następnie udostępnienie modelu w postaci interaktywnego, webowego prototypu aplikacyjnego (Proof of Concept).

Stos technologiczny (Tech Stack)

Do realizacji projektu wybrano nowoczesne i zoptymalizowane pod kątem obliczeń tensorowych środowisko programistyczne:

- **Język programowania:** Python
- **Biblioteki uczenia maszynowego i głębokiego:**
 - torch (PyTorch) – implementacja architektury sieci neuronowej, zarządzanie pętlą uczącą oraz obliczenia z wykorzystaniem akceleracji sprzętowej CUDA.
 - torchvision – wczytywanie, transformacje oraz zaawansowana augmentacja danych wejściowych.
- **Analiza danych i operacje matematyczne:**
 - numpy – operacje macierzowe i niskopoziomowa manipulacja strukturami obrazów.
 - pandas – zarządzanie strukturami tabelarycznymi i metadanymi.
 - scikit-learn – wyliczanie metryk i generowanie struktur ewaluacyjnych modelu.

- **Wizualizacja danych:**
 - matplotlib & seaborn – generowanie wykresów funkcji straty, dokładności (Accuracy) oraz macierzy pomyłek (Confusion Matrix).
- **Środowisko deweloperskie:** Visual Studio Code
- **Interfejs graficzny:** gradio – budowa funkcjonalnego, webowego interfejsu użytkownika obsługującego inferencję modelu w czasie rzeczywistym.


```
ai-breed-detector/
|
+-- data/
|   +-- raw/                (Pobrany dataset - ZIP z Kaggle i wypakowane foldery ras)
|   |   +-- dogs.zip
|   |   +-- dogs/
|   +-- processed/          (Przetworzone zdjęcia i podział na foldery: train/val/test)
|
+-- notebooks/              (Brudnopisy w Jupyterze - do wizualizacji danych i szybkich testów)
|
+-- src/                    (Katalog z kodem)
|   +-- data_prep.py        (Skrypt dzielący zdjęcia na zbiory i robiący augmentację)
|   +-- model.py             (Definicja architektury sieci, załadowanie np. ResNet)
|   +-- train.py             (Główna pętla ucząca model)
|   +-- app.py               (Skrypt z inferencją/aplikacją np. w Gradio lub Streamlit)
|
+-- saved_models/           (Wagi sieci po treningu, np. best_model.pth)
|
+-- results/                (Wykresy uczenia z dokładnością i macierz pomyłek)
|
+-- reports/                (Dokumentacja, kamienie milowe, raport końcowy)
|   +-- presentations/
|   |   +-- milestone-1.pdf
|   +-- project-structure.txt
|   +-- milestones.txt
|
+-- venv/                   (Środowisko wirtualne Pythona)
|
+-- requirements.txt
+-- .gitignore
+-- README.md
```

Architektura i struktura projektu

W celu zapewnienia powtarzalności eksperymentów, przejrzystości kodu oraz zgodności z dobrymi praktykami inżynierii oprogramowania (Clean Code / DevOps), repozytorium projektu zostało podzielone na logiczne moduły:

- data/ – separacja danych wejściowych na podfoldery raw/ (surowy zbiór z Kaggle) oraz processed/ (zdjęcia podzielone na podzbiory treningowe, walidacyjne i testowe).
- notebooks/ – przestrzeń na brudnopisy badawcze i wstępną analizę danych.

- src/ – właściwy kod źródłowy aplikacji (w tym odseparowane skrypty przygotowania danych data_prep.py, definicji architektury model.py, pętli uczącej train.py oraz aplikacji klienckiej app.py).
- saved_models/ – miejsce zapisu wag wytrenowanej sieci (best_model.pth).
- results/ – wygenerowane wykresy i macierze ewaluacyjne.




Kamień Milowy 2: Pozyskanie i przygotowanie zbioru danych (Data Preprocessing)

Charakterystyka źródłowego zbioru danych

W projekcie wykorzystano powszechny w badaniach nad wizją komputerową zbiór danych **Stanford Dogs Dataset**. Składa się on z ponad **20 000 zdjęć** psów pogrupowanych w **120 unikalnych klas** reprezentujących rasy z całego świata.

Zbiór ten charakteryzuje się wysokim stopniem skomplikowania: zdjęcia pochodzą z rzeczywistych środowisk, zawierają szum informacyjny (tło, ludzie, zróżnicowane oświetlenie), a obiekty docelowe występują w różnych skalach i orientacjach. Do każdego zdjęcia w formacie .jpg dołączona jest dedykowana antywzorcowa struktura metadanych w formacie .xml zawierająca:

- **Metadane obrazu:** Dokładna szerokość (width), wysokość (height) oraz głębokość kolorów (depth).
- **Adnotacje Bounding Box (bndbox):** Precyzyjne współrzędne kartezjańskie (xmin, ymin, xmax, ymax) określające prostokątny obszar zajmowany przez psa na danym zdjęciu.



Architektura potoku danych (Data Pipeline) krok po kroku


W celu przygotowania danych do procesu uczenia głębokich sieci neuronowych zaprojektowano i zaimplementowano dedykowany skrypt przetwarzający (src/data_prep.py). Działanie skryptu realizowane jest w sposób zautomatyzowany w czterech głównych krokach:

1. **Mapowanie plików i czyszczenie:** Parowanie każdego obrazu .jpg z odpowiadającym mu plikiem .xml. Na tym etapie następuje oczyszczanie nazw ras (np. usuwanie identyfikatorów systemowych WordNet stosowanych w ImageNet) do czytelnego formatu tekstowego.
2. **Podział na podzbiory (Data Splitting):** Zbiór danych dla każdej rasy z osobna został losowo podzielony na trzy niezależne podzbiory w proporcjach:
 - **Zbiór treningowy (train):** 80% – baza do aktualizacji wag modelu.
 - **Zbiór walidacyjny (val):** 10% – monitorowanie zjawiska przeuczenia (overfitting) w trakcie epok.
 - **Zbiór testowy (test):** 10% – ostateczna, niezależna ewaluacja skuteczności generalizacji modelu.
3. **Przetwarzanie graficzne (ROI Extraction):** Wykorzystując sparsowane współrzędne z plików .xml, skrypt dokonuje operacji kadrowania obrazu do tzw. Region of Interest (ROI). Z oryginalnego zdjęcia wycinany jest wyłącznie prostokąt zawierający psa. Następnie obrazy są konwertowane na jednolity profil kolorów RGB i zapisywane w nowej strukturze katalogów (data/processed/).
4. **Zapis metadanych klas:** Generowany jest centralny plik mapowania słownikowego classes.json, który przypisuje każdej unikalnej rasie unikalny identyfikator numeryczny (0 do 119), niezbędny dla warstwy klasyfikacyjnej sieci neuronowej.



Efekty ekstrakcji obiektów (Crop & Clean)

Zastosowanie ekstrakcji za pomocą Bounding Boxów pozwoliło na drastyczne zredukowanie szumu informacyjnego z tła (odcięcie elementów wnętrza, mebli, krajobrazów czy postaci ludzkich). Dzięki temu model w trakcie treningu skupia się wyłącznie na cechach fenotypowych zwierzęcia (tekstura sierści, kształt uszu, pyska), co bezpośrednio przekłada się na stabilność procesu optymalizacji wag i wyższą dokładność klasyfikacji.



Kamień Milowy 3: Wybór architektury i implementacja modelu AI



Ze względu na wysoki stopień trudności problemu i subtelne różnice wizualne między klasami (np. Siberian Husky vs Malamut), od początku projektu wykorzystywano technikę uczenia transferowego (Transfer Learning).

Proces doboru odpowiedniej sieci miał charakter iteracyjny. Początkowo, w trakcie realizacji trzeciego kamienia milowego, opierano się na klasycznych architekturach, przechodząc z podstawowego modelu **ResNet18** na znacznie głębszy **ResNet50**. Ostatecznie jednak, w finalnej wersji projektu, zdecydowano się na wdrożenie jeszcze nowocześniejszej architektury konwolucyjnej **ConvNeXt** (wstępnie wytrenowanej na potężnym zbiorze ImageNet). Zastosowanie tego modelu – stanowiącego bezpośrednią ewolucję i usprawnienie klasycznych sieci z rodziny ResNet – zapewniło znakomitą zdolność ekstrakcji głębokich cech wizualnych obrazu.

W finalnym modelu ConvNeXt starą warstwę klasyfikacyjną (Head) zastąpiono nową. Składała się ona z warstwy *Dropout* ($p=0.5$), skutecznie chroniącej sieć przed zjawiskiem przeuczenia, oraz warstwy w pełni połączonej, redukującej wyjście do 120 docelowych klas (ras psów).

Aby zmaksymalizować skuteczność sieci, zastosowano profesjonalną strategię tzw. dwuetapowego treningu (Fine-Tuning):

- **Etap I (Epoki 1-5):** "Kręgosłup" modelu ConvNeXt został zamrożony. Algorytm optymalizował wyłącznie wagi nowej "głowy", ucząc ją kategoryzacji obrazów na nowe rasy, co uchroniło głębokie, wyuczone wcześniej krawędzie i wzorce przed zniszczeniem.
- **Etap II (Epoki 6-20):** Odmrożono całą sieć. Włączono potężny optymalizator AdamW (z regularyzacją Weight Decay) oraz algorytm Cosine Annealing LR, który płynnie obniżał współczynnik uczenia wzdłuż krzywej cosinusa. Pozwoliło to modelowi wyspecjalizować się w mikrodetalach psiej anatomii, bardzo precyzyjnie dostrajając wszystkie wagi kręgosłupa ConvNeXt do nowego zadania.



Kamień Milowy 4: Ewaluacja wyników i optymalizacja modelu

Metodyka ewaluacji końcowej

Po zakończeniu fazy eksperymentów i optymalizacji hiperparametrów, ostatecznej ocenie poddano trzy architektury przetestowane w toku prac rozwojowych. Wszystkie modele zostały ewaluowane na odseparowanym i nieuczestniczącym w treningu zbiorze testowym o wielkości **2058 obrazów**. W celu wszechstronnej weryfikacji zdolności generalizacji sieci, obliczono następujące metryki:

- **Skuteczność ogólna (Top-1 Accuracy):** Procent predykcji, w których klasa o najwyższym prawdopodobieństwie była w 100% zgodna z rzeczywistą etykietą.
- **Skuteczność Top-3 Accuracy:** Miara określająca, czy właściwa rasa psa znajduje się wśród trzech klas o najwyższym stopniu prawdopodobieństwa zwróconym przez funkcję Softmax.
- **Średni wskaźnik F1-Score:** Średnia harmoniczna precyzji (*Precision*) i pełności (*Recall*), stanowiąca zbalansowaną ocenę jakości klasyfikacji dla wszystkich 120 klas.

Porównanie architektur i efekty optymalizacji

Proces optymalizacji opierał się na technice Transfer Learningu z dostrojeniem parametrów warstw klasyfikacyjnych. Poniższa tabela zestawia wyniki uzyskane przez poszczególne modele:

Architektura sieci	Skuteczność ogólna (Top-1)	Skuteczność Top-3	Status optymalizacji
ResNet18 (<i>Model bazowy</i>)	63.65\%	82.90\%	Wyraźne przeuczenie, niska dokładność.
ResNet50	85.86\%	97.52\%	Dobra stabilizacja, znaczny wzrost skuteczności.
ConvNeXt-Tiny (<i>Model docelowy</i>)	91.79\%	98.83\%	Najwyższa skuteczność generalizacji.

```
RAPORT Z EWALUACJI MODELU
=====
Skuteczność ogólna (Top-1): 63.65%
Skuteczność Top-3: 82.90%
Przetestowano na łącznie: 2058 obrazach.
```


```
RAPORT Z EWALUACJI MODELU
=====
Skuteczność ogólna (Top-1): 85.86%
Skuteczność Top-3: 97.52%
Przetestowano na łącznie: 2058 obrazach.
```

```
RAPORT Z EWALUACJI MODELU
=====
Skuteczność ogólna (Top-1): 91.79%
Skuteczność Top-3: 98.83%
Przetestowano na łącznie: 2058 obrazach.
```

Analiza macierzy pomyłek (Confusion Matrix)

W celu dokładnej identyfikacji klas, które model błędnie przyporządkowuje, wygenerowano Macierze Pomyłek (Confusion Matrix). Wizualne porównanie macierzy dla modelu bazowego (starego) oraz zoptymalizowanego (nowego) jednoznacznie wskazuje na silniejszą koncentrację punktów wzdłuż głównej przekątnej. Świadczy to o drastycznym ograniczeniu liczby błędnych predykcji poza diagonalą i wyeliminowaniu losowych pomyłek dla większości ze 120 klas.

Macierz pomyłek dla ConvNeXt-Tiny:



Analiza błędów i przypadków brzegowych

Pomimo bardzo wysokiej skuteczności ogólnej, szczegółowa analiza wykazała istnienie specyficznych klas, dla których model osiągał wyniki niższe od średniej:

- **Klasy o najwyższej skuteczności (100% Top-1 Accuracy):** m.in. *Afghan hound*, *African hunting dog*, *French bulldog*, *Sealyham terrier*, *Sussex spaniel*. Rasy te posiadają unikalne cechy fenotypowe (kształt uszu, charakterystyczne ubarwienie), co ułatwia ekstrakcję kluczowych cech przez filtry konwolucyjne.
- **Klasy o najniższej skuteczności (Top-1 Accuracy):** *Eskimo dog* (52%), *miniature poodle* (55%), *kuvasz* (58%), *Siberian husky* (62%).

Głównym powodem niższej dokładności w tej drugiej grupie jest bardzo wysokie podobieństwo międzyklasowe wewnątrz zbioru Stanford Dogs Dataset:

1. **Mylenie ras ze względu na umaszczenie i posturę:** Przykładowo, rasa *kuvasz* jest wizualnie niemal identyczna dla klasyfikatora jak *Pirenejski pies górski*. Obie rasy charakteryzują się zbliżoną budową anatomiczną oraz jednolicie białym, puszystym futrem.
2. **Podobieństwo wzorców sierści:** Podobne zjawisko występuje przy rasach takich jak *Siberian husky* i *Eskimo dog*, gdzie tekstura i rozkład plam na sierści wykazują potężny stopień korelacji, co utrudnia sieci jednoznaczną separację przestrzeni decyzyjnej.

Najgorsze predykcje dla ras (top-1):

Eskimo_dog (52%)

miniature_poodle (55%)


kuvasz (58%)

Siberian_husky (62%)



Wykresy procesu uczenia (Learning Curves)

Jako dowód prawidłowo przeprowadzonego procesu optymalizacji hiperparametrów (w tym odpowiednio dobranego współczynnika uczenia – *learning rate*), poniżej przedstawiono przebiegi funkcji straty oraz dokładności dla ostatecznego modelu ConvNeXt-Tiny w porównaniu do modeli wcześniejszych. Wykresy potwierdzają stabilną zbieżność algorytmu i brak zjawiska gwałtownego przeuczenia.



Kamień Milowy 5: Budowa prototypu (Proof of Concept) i prezentacja wyników

Stworzenie prostego interfejsu użytkownika

Ostatnim etapem projektu było stworzenie w pełni funkcjonalnego prototypu aplikacji w postaci webowego interfejsu graficznego. Do tego celu wykorzystano bibliotekę **Gradio**. Interfejs pozwala na przesłanie zdjęcia psa, a następnie przy użyciu przycisku wyświetlenie prawdopodobieństwa danej rasy.

```
customtheme=gr.themes.Soft(primary_hue="sky", neutral_hue='slate',).set(
    background_fill_primary="#0B132B",
    background_fill_secondary="#1C2541",
    block_background_fill="#1C2541",
    body_text_color="#E2E8F0",
    block_label_text_color="#E2E8F0",
    block_label_background_fill="#243388",
    block_label_border_color="#243388",
)
```

```
with gr.Blocks() as demo:
    gr.HTML("<h1 class='title'>AI Dog Breed Detector</h1>")


    with gr.Row():
        with gr.Column():
            input_img = gr.Image(type="pil", label="Wgraj zdjęcie psa")
            btn_predict = gr.Button("Rozpoznaj rasę", variant="primary")

        with gr.Column():
            output_labels = gr.Label(num_top_classes=3, label="Najbardziej prawdopodobna rasa psa")

    btn_predict.click(fn=predict_dog_breed, inputs=input_img, outputs=output_labels)
```


Przykład działania aplikacji

Zdjęcie Chihuahua



Na zdjęciu możemy zobaczyć przykład działania aplikacji dla zdjęcia psa należącego do siostry kolegi zrobionego telefonem. Widać tutaj, że model podał prawdopodobieństwo na poziomie 90% co jest dobrym wynikiem. Natomiast nie jest od bez wad co widać w przypadku ras bardzo podobnych do siebie.

Zdjęcie Siberian Husky



Model w tym przypadku miał problem z odpowiednim rozpoznaniem rasy psa na zdjęciu i przypisał większe prawdopodobieństwo dla rasy Eskimo dog. Jest to przypadek w którym dwie rasy są niemal identyczne i model ma problem z ich poprawnym rozróżnieniem.

Podsumowanie projektu i wnioski końcowe

W ramach projektu stworzyliśmy i trenowaliśmy model, który osiągnął zadowalającą skuteczność rozpoznawania ras psów na podstawie zdjęcia. Po przetestowaniu kilku architektur, naszym ostatecznym wyborem został model ConvNeXt-Tiny, który przeszedł proces dostrojenia wag (Transfer Learning).

Model osiągnął znakomitą skuteczność na zbiorze testowym:

- **Ogólna dokładność (Top-1 Accuracy): 91,79%** – co oznacza, że niemal 9 na 10 psów zostaje bezbłędnie przyporządkowanych do swojej rasy za pierwszym razem.
- **Dokładność Top-3: 98,83%** – w tym procencie przypadków prawidłowa rasa znajduje się w pierwszej trójce wskazań modelu.

Analiza działania i przypadki testowe Wysoką jakość klasyfikacji potwierdziły testy praktyczne. Świetnym przykładem była weryfikacja działania sieci na rzeczywistym zdjęciu Chihuahua (należącym do kolegi z zespołu) – model wykazał się tam pewnością na poziomie aż 90%. Wynika to z faktu, że rasy o tak unikalnych i wyrazistych cechach anatomicznych (specyficzny kształt głowy, duże uszy) są dla filtrów konwolucyjnych łatwe do jednoznacznej identyfikacji.

Z drugiej strony, szczegółowa analiza błędów pokazała, że sieć miewa naturalne trudności w obszarach o bardzo dużym podobieństwie międzyklasowym. Sporym wyzwaniem dla modelu było poprawne przyporządkowanie ras psów takich jak:

- **Eskimo dog** (spadek dokładności do 52%),
- **Siberian husky** (62%),
- **Alaskan malamute**.

Psy te posiadają niemal identyczną budowę ciała oraz charakterystyczne wzorce umaszczenia (maski na pyskach). Dla algorytmu ich przestrzenie decyzyjne mocno się przenikają, co czasami prowadzi do pomyłek wewnątrz tej grupy. Sytuację tę częściowo rozwiązuje jednak zaimplementowany przez nas interfejs, aplikacja nie zgaduje na siłę jednej rasy, lecz wyświetla rozkład prawdopodobieństwa Top-3, co pozwala na trafną interpretację wizualnych cech wspólnych u psów bliźniaczych oraz kundelków.